



Universidade Federal do Espírito Santo
Programa de Pós-Graduação em Informática

Artificial Bee Colony

Leandro Furlam Turi

Artificial Bee Colony (ABC)

Proposto por Karaboga (2008) como um algoritmo de inteligência de enxame baseado na observação do comportamento de forrageamento das abelhas.

Nele há um conjunto de fontes de alimento e um conjunto de abelhas. A qualidade das fontes de alimento é baseada na quantidade de néctar que elas contêm. As abelhas procuram e colaboram umas com as outras, buscando melhores fontes de alimento.



Artificial Bee Colony (ABC)

Para resolver um problema de otimização usando o ABC, as fontes de alimento representam a população de soluções para um determinado problema e as abelhas são categorizadas em três tipos: batedoras, funcionárias e observadoras. A quantidade de néctar corresponde à qualidade (função objetivo) do problema que está sendo tratado. Os três tipos de abelhas trabalham juntos de forma iterativa para melhorar a qualidade da população de soluções (fontes de alimento).



AN IDEA BASED ON HONEY BEE SWARM FOR NUMERICAL OPTIMIZATION

(TECHNICAL REPORT-TR06, OCTOBER, 2005)

Dervis KARABOGA

karaboga@ercives.edu.tr

Erciyes University, Engineering Faculty
Computer Engineering Department
Kayseri/Türkiye

I. INTRODUCTION

Swarm intelligence has become a research interest to many research scientists of related fields in recent years. Bonabeau has defined the swarm intelligence as “any attempt to design algorithms or distributed problem-solving devices inspired by the collective behaviour of social insect colonies and other animal societies” [1]. Bonabeau et al. focused their viewpoint on social insects alone such as termites, bees, wasps as well as other different ant species. However, the term swarm is used in a general manner to refer to any restrained collection of interacting agents or individuals. The classical example of a swarm is bees swarming around their hive; nevertheless the metaphor can easily be extended to other systems with a similar architecture. An ant colony can be thought of as a swarm whose individual agents are ants.

II. BEHAVIOUR OF HONEY BEE SWARM

The minimal model of forage selection that leads to the emergence of collective intelligence of honey bee swarms consists of three essential components: food sources, employed foragers and unemployed foragers and the model defines two leading modes of the behaviour: the recruitment to a nectar source and the abandonment of a source.



i) **Food Sources:** The value of a food source depends on many factors such as its proximity to the nest, its richness or concentration of its energy, and the ease of extracting this energy. For the sake of simplicity, the “profitability” of a food source can be represented with a single quantity [8].

ii) **Employed foragers:** They are associated with a particular food source which they are currently exploiting or are “employed” at. They carry with them information about this particular source, its distance and direction from the nest, the profitability of the source and share this information with a certain probability.



iii) **Unemployed foragers:** They are continually at look out for a food source to exploit. There are two types of unemployed foragers: scouts, searching the environment surrounding the nest for new food sources and onlookers waiting in the nest and



Artificial Bee Colony (ABC)

Passo 1: Inicializar parâmetros

Passo 2: Inicializar a população de soluções

Passo 3: Avaliar a população de soluções

enquanto a condição de término não for atendida **faça**

Passo 4: Etapa das abelhas funcionárias

Passo 5: Etapa das abelhas observadoras

Passo 6: Etapa das abelhas batedoras

fim-enquanto

Artificial Bee Colony

Inicializar a população de soluções

Um conjunto de soluções com tamanho igual a PS é gerado aleatoriamente da seguinte forma:

$$x_i = x_{\min} + \text{rand}[0,1](x_{\max} - x_{\min})$$

onde x_{\max} e x_{\min} são os limites máximo e mínimo da variável de decisão x .

Artificial Bee Colony

Etaapa das abelhas funcionárias

Cada abelha funcionária é enviada para uma fonte de alimento (solução). Sua principal função é explorar a vizinhança da solução atual, buscando uma solução melhorável. Uma solução de vizinhança, v , é criada modificando a i -ésima solução, x , como segue:

$$v_i = x_i + \text{rand}[-1,1](x_i - x_k)$$

onde x_k é gerado aleatoriamente na população. A solução de vizinhança gerada será substituída pela solução atual se tiver melhor aptidão.

Artificial Bee Colony

Etapa das abelhas observadoras

As abelhas observadoras procuram melhorar a população atual de soluções explorando sua vizinhança usando a mesma que a abelha funcionária. A diferença é que as abelhas observadoras selecionam as soluções probabilisticamente com base em seus valores de aptidão da seguinte forma:

$$p_i = \text{fitness} / \sum_{j=1}^{\text{PS}} (\text{fitness}_j)$$

Ou seja, a solução com maior aptidão tem maior chance de ser selecionada (seleção da roleta). As abelhas observadoras utilizam um mecanismo de seleção guloso, onde a melhor solução em termos de aptidão é selecionada.

Artificial Bee Colony

Etapa das abelhas batedoras

Esta etapa é ativada se as abelhas funcionárias e observadoras não puderem melhorar a solução atual por um número de iterações consecutivas definido pelo parâmetro limite, Lit . Isso indica que a solução atual não é boa o suficiente para pesquisar sua vizinhança e deve ser descartada. Nesse caso, a abelha exploradora gerará uma nova solução usando a Equação descrita no Passo 2 para substituir a descartada. Isso pode ajudar o ABC a escapar de um ótimo local e explorar uma área diferente do espaço de busca.

Modelagem do problema

Parâmetros

PS = 50

Lit = 30

max_it = 500

Modelagem do problema

Indivíduo (abelha)

Cada abelha representa K centróides em R^{n_var} , onde K é o número de clusters e n_var é a dimensão do espaço de variáveis de entrada.

Para simplificar os cálculos, todos os pontos foram rearranjados em um único vetor

$v = \{a_1, a_2, a_3, \dots, a_{n_var}, b_1, b_2, b_3, \dots, b_{n_var}, \dots, k_1, k_2, k_3, k_{n_var}\}$

setosa

versicolor

virginica

Modelagem do problema

Função Fitness

Cada um dos clusters descritos anteriormente é mapeado diretamente a uma das classes da base de dados. É calculada a norma euclideana entre cada observação da base de dados e o cluster de interesse, onde a classe mapeada do cluster mais próximo será a da observação.

Para avaliar a eficácia do método, é calculada a taxa de acertos em relação ao número total de observações.

Modelagem do problema

Função Fitness

```
target_map = {0: "setosa", 1: "versicolor", 2: "virginica"}

Y_pred = []
centroids = array_split(bee, K)
for row in X:
    distances = [L2(row - centroid) for centroid in centroids]
    Y_pred.append(target_map[argmax(distances)])

sum(Y_pred == Y)/len(Y)
```


Resultados

Base de dados	fitness treino	fitness teste	iter	time
Wine	0.766917	0.733333	499	1min 33s
Breast Cancer	0.924882	0.930069	499	4min 07s
Diabetes	+	+	499	2h 48min 35s

+: não houve convergência.


Resultados

Wine




Resultados

Breast Cancer



Resultados

Diabetes



Conclusão

Dada sua natureza semelhante às demais heurísticas Genéticas, o ABC demonstrou ser um bom candidato à classificação de dados quando o número de grupos é pequeno. Sua estrutura simples, porém poderosa, permitiu encontrar uma boa solução nas bases Wine ($k = 3$) e Breast Cancer ($k = 2$). Caso este que não ocorreu para base Diabetes ($k = 214$).

Destaca-se que sua implementação computacional pode ser otimizada e paralelizada, de forma a diminuir o tempo de execução.